

RAPPORT DE PROJET DE FIN D'ÉTUDES

Stage d'Ingénieur en Intelligence d'Affaires

LeadGen Francophone 360+

Plateforme Intelligente de Veille et de Génération
de Leads B2B IT en Zone Francophone

Organisme d'accueil : Solvinya Group
Encadrant entreprise : Équipe Technique Solvinya
Diplôme visé : Ingénieur en Informatique
Spécialité : Business Intelligence & IA
Durée du stage : 6 mois (Décembre 2025 – Mai 2026)
Date de soutenance : Mai 2026

Table des matières

Résumé	3
1 Introduction et Contexte	4
1.1 Contexte de l'entreprise	4
1.2 Objectifs du projet	4
1.3 Structure du rapport	5
2 Architecture Globale du Système	6
2.1 Vue macro	6
2.2 Choix technologiques	7
2.3 Les 5 types de signaux B2B	8
3 Méthodologie de Collecte des Données	9
3.1 Vue d'ensemble des collecteurs	9
3.2 Collecteur LinkedIn Jobs – Signal d'externalisation	9
3.2.1 Stratégie métier	10
3.2.2 Flux interne	10
3.2.3 Technologies et pays surveillés	11
3.3 Collecteur LinkedIn B2B – Publications d'entreprises	11
3.3.1 Contrainte technique	11
3.3.2 Patterns de détection regex	12
3.4 Collecteurs BOAMP et TED EU	12
3.5 Stratégie anti-détection	12
4 Pipeline d'Ingestion et Scoring	14
4.1 Architecture du pipeline	14
4.2 Formule de scoring de priorité	15
4.2.1 Exemples de calculs	16
4.3 Déduplication	16
5 Module de Classification NLP	18
5.1 Objectif et justification	18
5.2 Architecture du classifieur	18
5.3 Choix du modèle : TF-IDF vs Sentence-Transformers	19

5.4	Données d'entraînement	19
5.5	Performances du modèle	19
5.6	Intégration dans le pipeline	20
6	API REST et Génération LLM	21
6.1	Architecture de l'API FastAPI	21
6.2	Générateur de messages LLM	22
6.2.1	Exemple de message généré	22
7	Orchestration via n8n	23
7.1	Vue d'ensemble des 4 workflows	23
7.2	Workflow 03 – Démo Live Soutenance (8 nœuds)	23
7.3	Workflow 02 – BOAMP RSS avec classification NLP	24
8	Résultats et Évaluation	25
8.1	Volume de données collectées	25
8.2	Répartition par niveau de priorité	26
8.3	Performances du pipeline	27
8.4	Bilan de la démo de soutenance	27
9	Infrastructure et Déploiement	28
9.1	Architecture Docker Compose	28
9.2	Schéma de la base de données	29
10	Conclusion et Perspectives	30
10.1	Bilan du projet	30
10.2	Difficultés rencontrées	30
10.3	Perspectives d'évolution	30
A	Structure complète des fichiers	32
B	Commandes de référence (Makefile)	34
C	Variables d'environnement	35

Résumé

Résumé exécutif

LeadGen Francophone 360+ est une plateforme de génération de leads B2B entièrement automatisée, développée dans le cadre d'un stage d'ingénieur de six mois au sein de Solvinya Group. Elle cible les entreprises ayant des besoins actifs en services informatiques dans les pays francophones d'Europe (France, Belgique, Luxembourg, Suisse) et en Tunisie.

La plateforme collecte automatiquement des données depuis cinq sources (LinkedIn Jobs, LinkedIn B2B, BOAMP, TED EU et Malt.fr), qualifie chaque prospect avec un score de priorité [0; 100] basé sur des règles métier déterministes, classe les opportunités par secteur et priorité via un modèle NLP (TF-IDF + LinearSVC) et génère des messages LinkedIn et des emails de prospection personnalisés via un Large Language Model (Groq – llama-3.1-8b).

Indicateur	Valeur	Indicateur	Valeur
Prospects collectés	815	Accuracy NLP secteur	75%
Score moyen LinkedIn	81/100	Accuracy NLP priorité	85%
Sources actives	4/5	Latence génération LLM	1–3s
Pays couverts	5	Latence pipeline ingest	~50ms

Mots-clés : Python 3.11 · FastAPI · PostgreSQL · linkedin-api · NLP · TF-IDF · LinearSVC · n8n · Metabase · Docker · Groq API · B2B Lead Generation

Chapitre 1

Introduction et Contexte

1.1 Contexte de l'entreprise

Solvinya Group est une Entreprise de Services Numériques (ESN) spécialisée en intelligence artificielle et développement logiciel. Son activité principale consiste à fournir des équipes techniques à des clients B2B (banques, assurances, entreprises industrielles) dans les pays francophones européens et en Tunisie.

Problème métier

Sans outil automatisé, les commerciaux de Solvinya passent plusieurs heures par semaine à chercher manuellement sur LinkedIn, BOAMP et les journaux officiels pour obtenir quelques leads de qualité incertaine. Ce processus est non scalable, chronophage et ne permet pas de détecter les opportunités en temps réel.

1.2 Objectifs du projet

LeadGen Francophone 360+ répond à cinq objectifs opérationnels définis en début de stage :

1. **Collecter automatiquement** des signaux d'opportunités IT depuis des sources hétérogènes (LinkedIn, appels d'offres publics, plateformes freelance) toutes les 12 heures, sans intervention humaine.
2. **Qualifier** chaque prospect avec un score de priorité $[0; 100]$ basé sur des règles métier transparentes et reproductibles.
3. **Classifier** les opportunités par secteur et niveau de priorité via un modèle de traitement automatique du langage naturel (TALN).
4. **Générer automatiquement** des messages de prospection LinkedIn et des emails personnalisés via un LLM accessible gratuitement.

5. **Exposer** les résultats via une API REST et des dashboards Metabase consultables en temps réel par l'équipe commerciale.

1.3 Structure du rapport

Ce rapport est organisé en neuf chapitres. Le chapitre 2 présente l'architecture globale du système. Les chapitres 3 et 4 détaillent la méthodologie de collecte et le pipeline de traitement. Les chapitres 5 et 6 couvrent respectivement le module NLP et l'API REST. Le chapitre 7 décrit l'orchestration via n8n. Les chapitres 8 et 10 présentent les résultats obtenus et les perspectives d'évolution.

Chapitre 2

Architecture Globale du Système

2.1 Vue macro

Le système est structuré en cinq couches fonctionnelles indépendantes et communicantes, déployées via Docker Compose sur un seul hôte.




FIG. 2.1 : Architecture en couches du système LeadGen Francophone 360+

2.2 Choix technologiques

Composant	Technologie	Justification	Coût
Runtime	Python 3.11	Performance async native, écosystème ML	Gratuit
API REST	FastAPI	Auto-documentation Swagger, async, Pydantic	Gratuit
Base de données	PostgreSQL 15	ACID, JSONB, tableaux natifs, asyncpg	Gratuit
Orchestration	n8n (self-hosted)	Workflows visuels, webhooks, schedulers	Gratuit
BI Dashboard	Metabase	Connexion directe PostgreSQL, self-hosted	Gratuit
LinkedIn	linkedin-api	API mobile interne, moins détectable que Selenium	Gratuit
NLP	TF-IDF + LinearSVC	Supérieur sur vocabulaire IT restreint (>sentence-transformers)	Gratuit
LLM	Groq (llama-3.1-8b)	30 req/min gratuit, latence 1–3s	Gratuit
Déploiement	Docker Compose	Reproductibilité, isolation des services	Gratuit

TAB. 2.1 : Stack technologique – 100% open-source et gratuit

2.3 Les 5 types de signaux B2B

Signal	Définition et valeur commerciale	Source
outsourcing_signal	Entreprise non-IT recrutant un développeur IT. Logique : une banque qui recrute un dev COBOL a un besoin actif et un budget. Solvinya contacte le DSI avant que le recrutement aboutisse.	LinkedIn Jobs
b2b_tender	Appel d'offres public ou privé pour un projet IT. Ex : "Marché maintenance logiciel SAP – Mairie Paris".	BOAMP, TED EU
b2b_rfp	Demande de Proposition formelle (RFP/DDP). Signale un besoin structuré avec cahier des charges.	LinkedIn B2B
b2b_subcontracting	Recherche de prestataire, sous-traitant ou freelance IT. Ex : "Recherche prestataire Java pour projet 6 mois".	LinkedIn B2B, Malt
b2b_partnership	Partenariat stratégique, co-traitance ou consortium IT. Opportunité de positionnement long terme.	LinkedIn B2B

TAB. 2.2 : Taxonomie des 5 signaux B2B détectés par la plateforme

Chapitre 3

Méthodologie de Collecte des Données

3.1 Vue d'ensemble des collecteurs

Chaque collecteur hérite d'une classe abstraite `BaseCollector` qui standardise la gestion des logs, des erreurs et des métriques. La figure 3.1 illustre le flux de collecte.




FIG. 3.1 : Flux générique d'un collecteur vers la base de données

3.2 Collecteur LinkedIn Jobs – Signal d'externalisation

3.2.1 Stratégie métier

Ce collecteur implémente la logique de *hiring signal* : une entreprise non-IT (banque, assurance, industrie) qui recrute activement un développeur COBOL ou Java possède un projet IT actif avec un budget alloué. Solvinya peut contacter le DSI pour proposer une équipe externalisée, souvent disponible plus rapidement qu'un recrutement CDI pour un profil technique rare.

3.2.2 Flux interne




FIG. 3.2 : Flux interne du collecteur LinkedIn Jobs (linkedin_hiring.py)

3.2.3 Technologies et pays surveillés

Technologie	Boost	Ratio	Pays	Limite/tech
COBOL	+25		France	30 leads
Mainframe	+25		Tunisie	20 leads
Python	+15		Belgique	20 leads
Machine Learning	+15		Luxembourg	15 leads
SAP	+12		Suisse	15 leads
Data Engineer	+12			
Java	+10			
DevOps	+10			
Salesforce	+8			
React	+5			

Tab. 3.1 : Technologies et pays ciblés par le collecteur LinkedIn Jobs

3.3 Collecteur LinkedIn B2B – Publications d’entreprises

3.3.1 Contrainte technique

L’API LinkedIn non-officielle (`linkedin-api`) ne retourne aucun résultat avec le filtre `CONTENT` sur les publications. La stratégie adoptée est donc indirecte :

Stratégie effective :

1. `search_companies(``banque crédit France'')` → liste d’entreprises acheteuses
2. `get_company_updates_by_id(urn_id)` → 15 dernières publications de chaque entreprise
3. `_score_post(text)` via expressions régulières → détection de signaux B2B dans le texte libre

Filtre anti-ESN : les 200 premiers caractères sont analysés pour exclure les publications de prestataires vendant leurs propres services.

3.3.2 Patterns de détection regex

Expression régulière	Type signal	Boost
<code>rfp request for proposal demande de proposition</code>	<code>b2b_rfp</code>	+22
<code>appel d'offres marché public avis de marché</code>	<code>b2b_tender</code>	+20
<code>recherche prestataire sous-traitance</code>	<code>b2b_subcontracting</code>	+18
<code>partenariat co-traitance consortium</code>	<code>b2b_partnership</code>	+15

TAB. 3.2 : Patterns regex de détection des signaux B2B dans les publications LinkedIn

3.4 Collecteurs BOAMP et TED EU

Source	Mécanisme	Fréquence	Résultats
BOAMP	GET flux RSS <code>boamp.fr/avis</code> filtré par mots-clés IT (logiciel, développement, SI, DevOps, IA)	12h	236 prospects
TED EU	POST <code>api.ted.europa.eu/v3/notices/search</code> avec query expert (cpv-codes, buyer-country)	12h	422 prospects
Malt.fr	Playwright headless – bloqué par Cloudflare Bot Management	N/A	0

TAB. 3.3 : Synthèse des collecteurs BOAMP, TED EU et Malt.fr

3.5 Stratégie anti-détection

Mesures d'anti-détection LinkedIn

- **Délais gaussiens** : `random.gauss(4.0, 1.5)` secondes entre requêtes (distribution non-uniforme, mimant le comportement humain)
- **Pool de sessions** : rotation round-robin sur 2–3 comptes LinkedIn dédiés, chacun limité à 250 requêtes/jour
- **Cookies persistants** : les cookies de session sont sérialisés sur disque (volume Docker) pour éviter les ré-authentifications qui déclenchent des vérifications de sécurité
- **Heures de collecte** : planification entre 08h00 et 19h00 uniquement

- **Circuit breaker** : détection automatique de l'erreur CHALLENGE_REQUIRED et mise en pause du compte pendant 24h

Chapitre 4

Pipeline d'Ingestion et Scoring

4.1 Architecture du pipeline

Le fichier `pipeline/ingest.py` implémente une fonction `ingest_raw_dict()` qui traite chaque prospect en six étapes séquentielles, avec un temps de traitement moyen de 50ms via le driver asynchrone `asyncpg`.




FIG. 4.1 : Pipeline d'ingestion en 6 étapes (pipeline/ingest.py)

4.2 Formule de scoring de priorité

La priorité commerciale est calculée selon une somme pondérée de quatre dimensions quantifiables :

$$S = 0,30 \cdot S_{\text{pays}} + 0,25 \cdot S_{\text{tech}} + 0,25 \cdot S_{\text{secteur}} + 0,20 \cdot S_{\text{boost}}$$

où $S \in [0; 100]$ et chaque composante $S_i \in [0; 100]$.

Pays (30%)		Technologie (25%)		Secteur (25%)	
Luxembourg	100	COBOL	100	Finance/Banque	100
Suisse	95	Mainframe	100	Finance/Assurance	95
France	90	SAP	85	Finance	90
Belgique	85	Java	80	IA	75
Tunisie	65	Machine Learning	78	Tech/IA	72
		Data Engineer	75	Industrie/RH	70
		Python	70	Tech	65
		DevOps	70	CRM/Retail	60
		Salesforce	65	Santé	55
		React	55	Secteur public	50

TAB. 4.1 : Tables de valeurs pour la formule de scoring

4.2.1 Exemples de calculs

Exemple 1 — Score maximal : COBOL, Finance/Banque, Luxembourg, boost=25

$$S = (100 \times 0,30) + (100 \times 0,25) + (100 \times 0,25) + (100 \times 0,20) = \mathbf{100}$$

Exemple 2 — SAP, Industrie/RH, Belgique, boost=12 (TED EU)

$$S_{\text{boost}} = (12/25) \times 100 = 48$$

$$S = (85 \times 0,30) + (85 \times 0,25) + (70 \times 0,25) + (48 \times 0,20) = 25,5 + 21,25 + 17,5 + 9,6 = \mathbf{74}$$

Exemple 3 — Python, IA, Suisse, boost=15

$$S_{\text{boost}} = 60$$

$$S = (95 \times 0,30) + (70 \times 0,25) + (75 \times 0,25) + (60 \times 0,20) = 28,5 + 17,5 + 18,75 + 12 = \mathbf{77}$$

4.3 Déduplication

La déduplication est assurée au niveau SQL avant chaque insertion :

Listing 4.1 : Requête de détection de doublon (30 jours)

```
SELECT id FROM opportunities
WHERE company_id = $1
  AND technologies @> ARRAY['SAP']
  AND opportunity_type = 'b2b_tender'
  AND created_at > NOW() - INTERVAL '30 days';
-- Si un enregistrement est trouvé : SKIP (pas d'insertion)
```

La clé d'unicité pour les entreprises est la `linkedin_url`, gérée via la contrainte UNIQUE et la clause `ON CONFLICT DO UPDATE`.

Chapitre 5

Module de Classification NLP

5.1 Objectif et justification

Le scoring par règles est déterministe mais limité aux champs structurés (pays, technologie, secteur). Le module NLP classe le *texte libre* des opportunités (titre, description d'appels d'offres BOAMP/TED) pour :

- affiner le label de secteur sur des textes ambigus ;
- prédire la priorité commerciale (HIGH / MEDIUM / LOW) ;
- fournir un score de confiance exploitable dans Metabase.

5.2 Architecture du classifieur




FIG. 5.1 : Architecture du module NLP – deux classifieurs parallèles

5.3 Choix du modèle : TF-IDF vs Sentence-Transformers

Analyse comparative sur 604 exemples d'entraînement		
Modèle	Accuracy CV-5	Raison du choix
TF-IDF (word 1-3g + char 3-5g)	75,0%	✓ Vocabulaire IT distinct
Sentence-transformers (MiniLM-L12)	69,4%	Meilleur sur corpus larges
Logistic Regression seule	71,0%	Moins robuste multi-classes
Conclusion : Les n-grammes de mots capturent les termes techniques (COBOL, SAP, DevOps). Les n-grammes de caractères gèrent les variantes orthographiques (cybersécurité / cyber-sécurité / cybersecurity).		

5.4 Données d'entraînement




FIG. 5.2 : Distribution des 604 exemples d'entraînement par secteur

5.5 Performances du modèle

Métrique	Classifieur Secteur	Classifieur Priorité
Cross-validation 5-fold	75,0% ± 4%	N/A
Accuracy (test set 20%)	70,2%	85,0%
F1-macro	68%	N/A
Seuil de production	≥ 75% CV	≥ 80%

TAB. 5.1 : Performances des classifieurs NLP

5.6 Intégration dans le pipeline

La classification NLP est déclenchée à la demande via l'endpoint `POST /api/classify`. Elle enrichit ensuite la table `opportunities` en mettant à jour les colonnes `sector_label`, `priority_label` et `nlp_confidence`.

Listing 5.1 : Exemple d'appel à l'endpoint de classification

```
curl -X POST http://localhost:8000/api/classify \
  -H "X-API-Key: leadgen360_demo_secret_2024" \
  -d '{"text": "Appel d offres prestataire COBOL Mainframe en banque"}'

# Reponse :
# {"sector_label": "Finance/Banque", "priority_label": "HIGH",
#  "sector_confidence": 0.92, "priority_confidence": 0.88}
```

Chapitre 6

API REST et Génération LLM

6.1 Architecture de l'API FastAPI

L'API REST expose tous les services de la plateforme via des endpoints sécurisés (authentification par en-tête X-API-Key). Elle est documentée automatiquement via Swagger UI (/docs).

Méthode	Route	Rôle	Latence
GET	/health	Santé API + ping PostgreSQL	<5ms
POST	/api/ingest	Ingestion manuelle (tableau de prospects)	~50ms
POST	/api/classify	Classification NLP texte libre	~100ms
GET	/api/prospects	Liste filtrée (pays, secteur, min_score)	~30ms
POST	/api/generate/message	Génération message LinkedIn via Groq	1–3s
POST	/api/generate/email	Génération email de prospection	1–3s
POST	/api/collect/linkedin	Lance collecte LinkedIn (BackgroundTask)	immédiat
POST	/api/collect/all	Lance collecte complète (BackgroundTask)	immédiat

TAB. 6.1 : Catalogue des endpoints FastAPI

6.2 Générateur de messages LLM




FIG. 6.1 : Pipeline de génération de messages LinkedIn via Groq LLM

6.2.1 Exemple de message généré

Entrée : BNP Paribas · COBOL · France · outsourcing_signal · score=95

Bonjour [Prénom],
J'ai remarqué que BNP Paribas recrute activement des profils COBOL en ce moment.
Chez Solvinya Group, nous disposons d'une équipe COBOL/Mainframe disponible
immédiatement — nous intervenons souvent quand le recrutement prend trop de temps
ou que la mission est trop courte pour justifier un CDI.
Vous travaillez sur une migration ou une maintenance de système legacy?

Chapitre 7

Orchestration via n8n

7.1 Vue d'ensemble des 4 workflows

n8n est déployé en mode self-hosted (Docker, port 5678) et orchestre l'ensemble des tâches récurrentes de la plateforme.

N°	Nom	Déclencheur	Objectif
01	LinkedIn Hiring Collector	Schedule toutes les 6h	Collecte LinkedIn basique
02	BOAMP RSS + NLP	Schedule toutes les 12h	AO publics + classification
03	Live Demo Soutenance	Manuel	Pipeline complet en 90s
04	Collect Trigger	Schedule 12h + Webhook	Collecte complète (recommandé)

TAB. 7.1 : Les 4 workflows n8n de la plateforme

7.2 Workflow 03 – Démo Live Soutenance (8 nœuds)

Ce workflow est le plus important : il démontre le pipeline complet de bout en bout en une seule exécution manuelle.




FIG. 7.1 : Workflow 03 – Pipeline de démonstration en 8 nœuds

7.3 Workflow 02 – BOAMP RSS avec classification NLP




FIG. 7.2 : Workflow 02 – Classification automatique des appels d’offres BOAMP

Chapitre 8

Résultats et Évaluation

8.1 Volume de données collectées

Au 2 mai 2026, la plateforme a collecté et qualifié **815 prospects** répartis sur 5 pays et 4 sources actives.




FIG. 8.1 : Distribution des 815 prospects par source et pays

Source	Pays	Prospects	Score moy.	Signal
BOAMP	FR	236	66	b2b_tender
TED	FR	145	65	b2b_tender
TED	BE	105	63	b2b_tender
TED	CH	98	65	b2b_tender
TED	LU	74	66	b2b_tender
LinkedIn Jobs	FR	122	79	outsourcing_signal
LinkedIn Jobs	BE	12	83	outsourcing_signal
LinkedIn Jobs	TN	11	75	outsourcing_signal
LinkedIn Jobs	LU	10	84	outsourcing_signal
LinkedIn Jobs	CH	2	87	outsourcing_signal
TOTAL		815		

TAB. 8.1 : Détail des prospects collectés par source et pays

8.2 Répartition par niveau de priorité




FIG. 8.2 : Répartition des 815 prospects par plage de score de priorité

8.3 Performances du pipeline

Étape du pipeline	Latence	Technologie
Collecte BOAMP / TED	0,3s / prospect	httpx async
Collecte LinkedIn	~2s / prospect	linkedin-api + anti-détection
Normalisation	<5ms	Python
Upsert + déduplication + scoring	~50ms	asynctpg
Classification NLP	~100ms	TF-IDF + LinearSVC
Génération message Groq	1-3s	Groq llama-3.1-8b

TAB. 8.2 : Latences mesurées pour chaque étape du pipeline

8.4 Bilan de la démo de soutenance

Le workflow 03 de démonstration live s’exécute en ~8 secondes de bout en bout : ingest d’un prospect COBOL (BNP Paribas), stockage PostgreSQL, récupération des top prospects, génération du message LinkedIn via Groq. Le prospect injecté apparaît simultanément dans le dashboard Metabase en temps réel.

Indicateurs clés du projet			
815	prospects collectés	5	pays couverts
4	sources actives (5 prévues)	75%	accuracy NLP secteur
85%	accuracy NLP priorité	158	prospects score ≥ 80
604	exemples entraînement	1-3s	latence génération LLM

Chapitre 9

Infrastructure et Déploiement

9.1 Architecture Docker Compose

La plateforme est entièrement containerisée et se déploie en une seule commande.

Listing 9.1 : Démarrage de la plateforme complète

```
# Demarrage de tous les services
docker-compose up -d

# Acces aux services
# FastAPI : http://localhost:8000/docs
# n8n : http://localhost:5678
# Metabase : http://localhost:3000
```

Service	Image	Port	Rôle
postgres	postgres:15-alpine	5432	Base de données principale
redis	redis:7-alpine	6379	Cache sessions + rate limiting
api	build ./api	8000	FastAPI + collecteurs
n8n	n8nio/n8n:latest	5678	Orchestration workflows
metabase	metabase/metabase:latest	3000	Dashboards BI

TAB. 9.1 : Services Docker Compose de la plateforme

9.2 Schéma de la base de données




FIG. 9.1 : Schéma entité-relation de la base de données PostgreSQL

Chapitre 10

Conclusion et Perspectives

10.1 Bilan du projet

LeadGen Francophone 360+ atteint l'ensemble des objectifs définis en début de stage. La plateforme collecte automatiquement 815 prospects qualifiés depuis 4 sources actives (LinkedIn Jobs, LinkedIn B2B, BOAMP, TED EU), les classe par secteur et priorité avec une accuracy de 75% (NLP secteur) et 85% (priorité), et génère des messages de prospection personnalisés en 1 à 3 secondes.

Les choix techniques – mono-repo Python, linkedin-api pour contourner les limites de l'API officielle, TF-IDF surclassant les sentence-transformers sur ce corpus restreint et spécialisé, Groq gratuit comme LLM – ont tous été justifiés par des benchmarks ou des contraintes opérationnelles documentées.

10.2 Difficultés rencontrées

- **Malt.fr** : le Cloudflare Bot Management bloque toute tentative de scraping (httpx, Playwright), rendant ce collecteur inopérant. Solution envisagée : proxy résidentiel ou API partenaire.
- **LinkedIn B2B** : l'API non-officielle ne permet pas la recherche dans le contenu des posts. La stratégie indirecte (scraping des mises à jour d'entreprises + regex) est fonctionnelle mais plus lente.
- **CHALLENGE_REQUIRED** : des sessions LinkedIn ont été bloquées lors des phases de test intensif. La stratégie de comptes multiples avec rotation et délais gaussiens a résolu le problème en production.

10.3 Perspectives d'évolution

1. **Court terme (M7-M8)** : intégration de l'envoi automatique des messages LinkedIn via l'API Phantombuster ou une extension Chrome dédiée ; ajout

d'un module de tracking des réponses.

2. **Moyen terme (M9-M12)** : collecte de nouvelles sources (Kompass, Europages, Journals officiels BE/LU) ; fine-tuning du modèle NLP sur des données réelles de conversion.
3. **Long terme** : déploiement cloud (AWS ou OVH), API multi-tenant pour d'autres ESN francophones, tableau de bord de ROI commercial (ratio leads générés / contrats signés).

Impact business estimé

Sur la base des 815 prospects actuels, avec un taux de conversion estimé à 2-5% (standard B2B IT), la plateforme peut générer **16 à 41 opportunités commerciales qualifiées** par semestre, contre 5 à 10 en mode manuel. Le retour sur investissement est immédiat puisque toute la stack est open-source et gratuite.

Annexe A

Structure complète des fichiers

Listing A.1 : Arborescence du projet leadgen360/

```
leadgen360/
+-- api/
|   +-- Dockerfile
|   +-- main.py          # FastAPI app : lifecycle, CORS, routers
|   +-- auth.py          # Middleware X-API-Key
|   +-- routes/
|       +-- health.py    # GET /health
|       +-- ingest.py     # POST /api/ingest
|       +-- classify.py    # POST /api/classify
|       +-- generate.py   # POST /api/generate/message + /email
|       +-- prospects.py  # GET /api/prospects
|       +-- collect.py    # POST /api/collect/*
+-- collectors/
|   +-- base.py
|   +-- linkedin_hiring.py # LinkedIn Jobs -> outsourcing_signal
|   +-- linkedin_b2b.py    # LinkedIn Posts -> b2b_*
|   +-- linkedin_client.py # Wrapper async linkedin-api
|   +-- session_manager.py # Pool comptes, round-robin
|   +-- boamp.py           # API BOAMP open data
|   +-- ted.py             # API TED EU
|   +-- malt.py            # Cloudflare bloque actuellement
|   +-- run_all.py         # Orchestrateur CLI
+-- pipeline/
|   +-- ingest.py          # Upsert, dedup 30j, scoring, INSERT
|   +-- scorer_rules.py    # compute_rule_score()
|   +-- enricher.py        # Hunter.io email lookup
+-- nlp/
|   +-- classifier.py      # TF-IDF + LinearSVC
|   +-- trainer.py         # Entrainement + validation 75% CV
|   +-- evaluator.py       # Metriques, confusion matrix
|   +-- data/
|       | +-- training_data.py # 604 exemples labelises
|       +-- models/           # sector_model.joblib, priority_model.
|                               joblib
+-- automation/
```

```
|   +-- llm_client.py           # Groq + Ollama fallback
|   +-- message_generator.py    # Prompt LinkedIn
|   +-- email_generator.py      # Prompt email
+-- db/
|   +-- init.sql                # CREATE TABLE + INDEX + triggers
|   +-- client.py               # Pool asyncpg
+-- config/
|   +-- settings.py             # Pydantic BaseSettings
+-- n8n_workflows/
|   +-- 01_linkedin_hiring.json
|   +-- 02_boamp_rss.json
|   +-- 03_live_demo.json
|   +-- 04_collect_trigger.json
+-- tests/
|   +-- test_api.py
|   +-- test_nlp.py
|   +-- test_pipeline.py
+-- docker-compose.yml
+-- Makefile
+-- pyproject.toml
```

Annexe B

Commandes de référence (Makefile)

Listing B.1 : Commandes Makefile disponibles

```
# Infrastructure
make up          # Demarre tous les services Docker
make down        # Arrete tous les services

# Collecte
make collect      # Lance tous les collecteurs
make collect-dry  # Mode dry-run (sans insertion)
make collect-boamp # BOAMP uniquement
make collect-ted  # TED EU uniquement
make collect-linkedin # LinkedIn hiring signal

# NLP
make train        # Entraîne les modeles NLP (>= 75% CV)

# Base de donnees
make db-shell     # Shell psql interactif
make db-stats     # Stats prospects par source/pays/score

# Tests
make test         # pytest (API + NLP + pipeline)

# Demo
make demo         # Declenche le workflow 03 via curl
```

Annexe C

Variables d'environnement

Listing C.1 : Fichier .env.example

```
# PostgreSQL
POSTGRES_DB=leadgen360
POSTGRES_USER=solvinya
POSTGRES_PASSWORD=changeme_en_prod

# LinkedIn (jusqu'a 3 comptes)
LINKEDIN_EMAIL_1=compte.scraping1@gmail.com
LINKEDIN_PASSWORD_1=motdepasse1
LINKEDIN_EMAIL_2=compte.scraping2@gmail.com
LINKEDIN_PASSWORD_2=motdepasse2

# LLM (gratuit)
GROQ_API_KEY=gsk_votre_cle_groq
GROQ_MODEL=llama-3.1-8b-instant

# LLM local (fallback)
OLLAMA_BASE_URL=http://localhost:11434
OLLAMA_MODEL=mistral

# API
API_SECRET_KEY=leadgen360_demo_secret_2024

# Enrichissement (optionnel)
HUNTER_API_KEY=votre_cle_hunter
```

Bibliographie

- [1] *linkedin-api – Unofficial LinkedIn API for Python*, Tom Quirk, 2023. <https://github.com/tomquirk/linkedin-api>
- [2] Sebastián Ramírez, *FastAPI – Modern, fast web framework for building APIs with Python*, 2019. <https://fastapi.tiangolo.com>
- [3] Pedregosa et al., *Scikit-learn : Machine Learning in Python*, Journal of Machine Learning Research, 12 :2825–2830, 2011.
- [4] *Groq API – Ultra-low latency inference*, Groq Inc., 2024. <https://console.groq.com>
- [5] Salton, G. and Buckley, C., *Term-weighting approaches in automatic text retrieval*, Information Processing & Management, 24(5) :513–523, 1988.
- [6] *API BOAMP – Bulletin Officiel des Annonces des Marchés Publics*, Direction de l’information légale et administrative, France. <https://www.boamp.fr>
- [7] *TED – Tenders Electronic Daily, API v3*, Office des publications de l’Union européenne. <https://api.ted.europa.eu>
- [8] *n8n – Workflow Automation Tool*, n8n.io, 2019. <https://n8n.io>
- [9] *Metabase – Business Intelligence Tool*, Metabase, Inc., 2015. <https://www.metabase.com>